


Proyecto Final

1. Identificar un proceso ya sea personal, académico o profesional que necesiten automatizar o resolver a través de los servicios de GCP.
2. Realizar un **diagrama** utilizando la herramienta de su preferencia en el cual muestre los servicios de GCP que utilizará dependiendo de sus necesidades.
3. Debe realizar una descripción de cada uno de los pasos en su solución.

- Descripción del entregable
 - **PDF** con el detalle de la solución o
 - Link del repo en Github (README.md).
- Recomendaciones
 - Intentar identificar un proceso que utilice 3 o más de 3 servicios de GCP (mandatory).
 - De preferencia utilizar solo herramientas de GCP.

- Ejemplos de grupos anteriores:

Se requiere desarrollar un ETL para cargar un conjunto de datos utilizando los servicios de Google Cloud Platform. La información obtenida será utilizada para análisis Financieros.



ARQUITECTURA DE WEBSCRAPING

Necesidad:

Nuestro software ERP para la construcción permite mostrar los precios de materiales de distintas webs de Latinoamérica, facilitando a los usuarios la inclusión de estos datos en sus presupuestos. Para ello, hemos implementado una arquitectura en GCP que realiza web scraping en sitios protegidos, utilizando Cloud Composer como orquestador.



SOLUCION

Firestore: Se utiliza una sencilla aplicación para registrar las categorías y URLs necesarias para el web scraping.

Cloud Run: Una imagen contiene una colección de scripts para realizar el web scraping en diversas páginas, guardando los resultados en archivos CSV con el formato [dominio]-[yyyy-mm-dd] en Cloud Storage. Para reducir la protección antibots, se utiliza navegador Firefox con Selenium. Las IPs dinámicas son importantes para evitar el bloqueo de IP.


Cloud Composer:

- Un DAG se ejecuta cada 7 días y levanta hasta 3 instancias de Cloud Run, asignándoles su carga de trabajo.
- Un DAG con un sensor detecta nuevos archivos en Cloud Storage, los procesa para limpiar los datos y los registra en una tabla de Cloud SQL.
- Un DAG detecta cuándo un Cloud Run no tiene carga y lo detiene.



Proceso para calcular el número ideal de réplicas en los pods.

Se trata de un proceso relacionado con el rightsizing o HPA (horizontal pod autoscaling), definiendo algunos límites mínimos y máximos para la generación de réplicas en nuestros pods de Kubernetes.




1. Se extraen los datos desde Cloud Monitoring. Datos como CPU Utilization and Memory Utilization, tomando distintos estadísticos con una ventana de tiempo de una hora.
2. Se realizan fórmulas en base a ciertos parámetros establecidos para determinar el número ideal de réplicas que deberían tener los pods de cada equipo.
3. Se llevan estos datos a BigQuery, a una tabla.
4. La data puede contener algunos errores, como por ejemplo, el cambio del horario de verano, causando duplicados o data faltante. Esto lo vamos a manejar como una vista.
5. Finalmente, estos datos son mostrados en un tablero de Tableau.

Problema: Sistema para hacer web scraping de precios de productos de diferentes páginas de tiendas, almacenar el histórico de precios y visualizarlos en un dashboard.

1. Cloud Scheduler
 - Funciona como un programador de tareas
 - Activa la función de scraping cada cierto tiempo (ejemplo: cada día a las 8am)
2. Cloud Functions
 - Se activa cuando Cloud Scheduler la llama
 - Ejecuta el código de web scraping que visita las páginas web
 - Extrae los precios de los productos
 - Envía los datos extraídos a BigQuery
3. BigQuery
 - Base de datos que guarda toda la información
 - Almacena: ID del producto, precio, tiendas, fecha de captura
 - Mantiene el histórico de todos los precios
4. Looker
 - Lee los datos desde BigQuery
 - Crea gráficos y dashboards para visualizar:
 - Tendencias de precios
 - Comparativas entre tiendas
 - Alertas de cambios de precios

Diagrama:



Servicios Utilizados

1. **Amazon Aurora y SAP B1 HANA:**
 - Fuentes de datos.
2. **AWS Lambda:**
 - Extracción y carga de datos crudos a BigQuery.
3. **Cloud Storage**
4. **BigQuery:**
 - Almacenamiento de las tres capas:
 - Tablas crudas (Raw Layer).
 - Tablas transformadas (Staging Layer).
 - Tablas finales (Presentation Layer).
 - Transformaciones SQL para mover los datos entre capas.
5. **Looker Studio:**
 - Visualización de datos desde la Capa de Presentación.



Nota: Se incluyen servicios de AWS en este proyecto debido a una casuística real de una empresa donde trabajé, en la que se requería aprovechar la infraestructura existente en AWS. Sin embargo, el análisis de la información se realiza utilizando los servicios de GCP (BigQuery y Looker Studio), permitiendo así aprovechar las fortalezas de ambas plataformas y facilitar la interoperabilidad entre ellas.